



## 4. 딥러닝의 응용

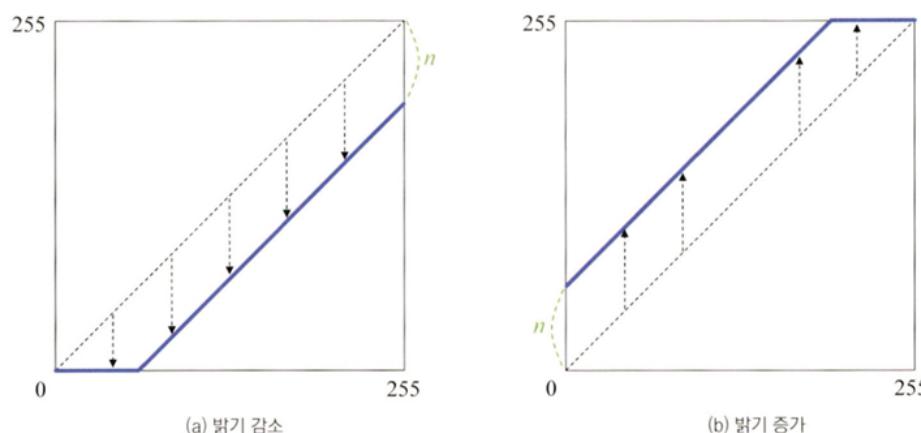
### 밝기 조절

#### 개요

영상의 밝기 조절은 전체 픽셀 값에 일정한 비율 또는 상수를 더하거나 빼는 방식으로 이루어진다. 밝기를 높이면 화면이 전체적으로 환해지고 낮추면 어둡게 표현된다. 수행 과정이 단순하고 결과가 즉각적으로 나타나기 때문에 가장 빠르고 직관적으로 시각 효과를 조절할 수 있는 전처리다.

밝기 조절의 핵심은 모든 픽셀 값에 일정한 양을 더하거나 빼는 연산을 적용해 영상의 전체적인 조도를 변화시키는 것이다. 조도는 어떤 물체나 공간에 도달하여 눈에 들어오는 빛의 양을 나타내는 밝기의 정도를 의미한다. 예를 들어 밝기를 +50으로 조정하면 모든 픽셀 값에 50을 더해 화면이 밝아지고 -40으로 조정하면 모든 픽셀 값에서 40을 빼어 화면이 어두워진다. 단, 연산 결과가 0보다 작아지거나 255보다 커지는 경우가 발생할 수 있으므로 최종 값은 0~255 범위에 맞춰 클리핑<sup>Clipping</sup> 해야 한다. 클리핑은 픽셀 값이 표현 가능한 범위를 벗어나지 않도록 결괏값을 0~255 사이로 제한하는 과정이며 어두운 이미지 보정이나 그림자 제거와 같이 조명 환경을 개선하는 목적으로 자주 사용된다. 딥러닝 전처리에서도 과도하게 밝거나 어두운 데이터로 인해 발생하는 편향을 줄여 학습 안정성과 모델 성능을 높이는 데 중요한 역할을 한다.

밝기 조절을 보다 정확하게 이해하기 위해서는 먼저 영상이 어떤 방식으로 픽셀값을 표현하는지 살펴볼 필요가 있다. 대표적인 영상 형식인 그레이스케일<sup>Grayscale</sup> 영상은 단일 채널로 구성되며 픽셀값이 0부터 255까지의 범위로 밝기를 나타낸다. 값이 0이면 완전한 검정이고 255면 완전한 흰색이며 그 사이의 값들은 회색 단계에 해당한다. 이러한 구조를 이해하면 밝기 조절 연산이 어떤 원리로 픽셀값에 일정량을 더하거나 빼는 방식으로 이루어지는지 직관적으로 이해할 수 있다. 또한 그레이스케일에서의 개념은 컬러 영상으로 그대로 확장되는데 RGB 이미지에서도 각 채널에 동일한 밝기 연산을 적용하는 방식으로 조절이 이루어진다. 딥러닝 전처리에서는 연산 비용을 줄이고 특징 추출에 집중하기 위해 컬러 이미지를 그레이스케일로 변환해 사용하는 경우가 많으며 CNN 기본 실습에서도 가장 널리 활용되는 전처리 기법이다.

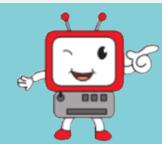


**그림** 파란색 실선으로 표시된 그래프는 영상의 밝기 조절 과정을 보여준다. 가로축은 입력 영상의 그레이스케일 값이고 세로축은 밝기 조절 후 출력 영상의 그레이스케일 값을 의미한다. 각 픽셀 값에 상수  $n$ 을 더하거나 빼는 연산이 적용되며 그 크기에 따라 영상 전체의 명암이 달라진다.

왼쪽 그림은 상수  $n$ 이 음수일 때의 변화를 보여 준다. 입력 값보다 더 낮은 출력값이 생성되므로 전체적으로 픽셀값이 감소하고 결과적으로 영상이 어두워진다. 감소된 정도는 그래프가 아래쪽으로 평행 이동한 형태로 표현되며 모든 픽셀값이 동일한 폭으로 내려간 모습으로 묘사된다.

오른쪽 그림은 상수  $n$ 이 양수일 때의 예로 입력 값보다 높은 출력 값이 생성되며 픽셀 값이 전체적으로 증가한다. 이로 인해 영상이 더 밝아지고 화면이 환하게 보인다. 그래프가 일정량 위쪽으로 평행 이동한 형태로 나타나며 밝기 향상이 균등하게 적용되고 있음을 알 수 있다.

즉, 입력 영상의 각 픽셀값에 상수  $n$ 을 더하면 영상이 밝아지고 상수  $n$ 을 빼면 어두워지는 원리를 그래프로 직관적으로 보여 준 것으로 그래프의 이동 방향과 이동량만 보아도 영상 밝기 변화의 특징을 쉽게 이해할 수 있다.





## 4. 딥러닝의 응용

### 요소

밝기 조절을 구현하려면 여러 가지 요소를 함께 고려해야 한다. 각 요소는 구현의 정확성, 작동 안정성, 처리 성능에 영향을 미치므로 모두 균형 있게 이해하고 적용하는 것이 중요하다.

#### ● 픽셀 순회

이미지의 각 픽셀을 반복문으로 하나씩 접근해 밝기 보정 값을 더하거나 빼는 방식이다. 구현이 단순하고 직관적이지만, 고해상도 이미지에서는 반복 횟수가 많아 처리 속도가 느려질 수 있다.

#### ● 벡터화된 연산

반복문 대신 넘파이 배열 연산을 사용해 전체 픽셀에 한 번에 밝기 값을 적용하는 방식이다. 코드가 간결해지고 CPU의 벡터 연산 최적화가 적용되어 실행 속도가 크게 향상된다.

#### ● 오버플로 방지

$dst(\text{출력 픽셀값}) = \text{src}(\text{입력 픽셀값}) + n(\text{밝기 증가량})$ 과 같이 밝기 증가 연산인 시 값이 255를 초과하여 원치 않는 wrap-around 현상이 발생할 수 있다. wrap-around 현상은 연산 결과가 표현 범위를 초과하거나 부족할 때 값이 다시 처음으로 되돌아가며 엉뚱한 숫자로 바뀌는 오류를 의미한다. 예를 들어  $250 + 200 = 270$ 이 되지 않고 14로 바뀌는 현상이 생길 수 있어 상한 제한이 필요하다.

#### ● 언더플로 방지

$dst(\text{출력 픽셀값}) = \text{src}(\text{입력 픽셀값}) - n(\text{밝기 증가량})$ 과 같이 밝기 감소 연산 시 값이 0보다 작아지면 wrap-around 현상으로 인해 0 이하의 값이 255 근처의 큰 값으로 바뀌는 문제가 발생한다. 따라서 결과가 0 아래로 내려가지 않도록 하한 제한이 필요하다.

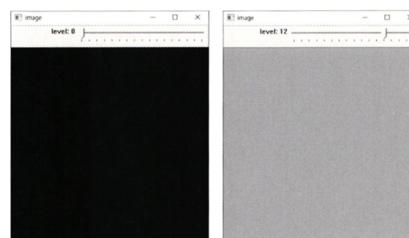
#### ● 연산 속도 최적화

밝기 조절을 실시간으로 적용해야 하는 경우에 카메라 영상, 사용자 인터랙션 등의 성능이 매우 중요하다. 사용자 인터랙션은 사용자가 시스템 또는 화면 요소를 직접 조작하거나 반응하며 결과를 확인하는 상호작용 과정을 의미한다. 불필요한 반복문을 줄이고 넘파이의 벡터화, 데이터 타입 일치, 메모리 복사 최소화 등의 기법을 적용하면 속도가 향상된다.

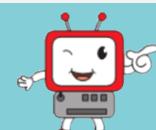
특히 딥러닝 전처리에서 밝기 조절의 핵심 원리를 이해하면 Data Augmentation<sup>오그멘테이션</sup> 전략 설계에 유리하다. 이 설계는 딥러닝에서 원본 데이터에 회전, 좌우 반전, 확대 및 축소, 밝기 및 명암비 조절, 노이즈 추가 등의 각종 변환을 적용해 새로운 학습용 데이터를 인위적으로 만들어 내는 기법이다.

### 트랙바 Trackbar

트랙바를 이용하여 영상의 밝기를 조절할 수 있다. 트랙바는 사용자가 GUI에서 슬라이더를 움직여 변수값을 실시간으로 변경할 수 있도록 해주는 도구다. 실습 환경에서 밝기 수치를 조절할 때 영상이 바로 어떻게 변하는지 눈으로 확인할 수 있어 이해도가 높아진다. 상호작용을 기반으로 영상 전처리의 시각적 효과를 자연스럽게 체험할 수 있는 대표적인 실습 방식이다.



**그림** 트랙바를 이용해 영상의 밝기를 조절했을 때 출력 영상이 어떻게 달라지는지를 비교하여 보여준다. 두 화면은 모두 동일한 입력 영상을 사용하고 있으며 차이는 트랙바로 설정한 밝기 수준값이다. 왼쪽 화면의 트랙바 값이 0으로 표시되어 있으며 밝기 조절값이 적용되지 않은 상태다. 픽셀값이 대부분 낮은 범위에 머물러 있어 화면 전체가 거의 검정에 가깝게 보인다. 이는 입력 영상에 밝기 보정이 더해지지 않은 상태를 나타내며 가장 어두운 결과를 보여준다. 오른쪽 화면의 트랙바 값이 12로 표시되어 있으며 밝기 조절값이 양수 방향으로 크게 증가한 상태다. 픽셀값이 전체적으로 높은 값으로 이동하면서 영상이 밝게 표현되고 전체 화면이 화색 톤으로 보인다. 즉, 동일한 영상이라도 밝기 조절 수치에 따라 시각적 인상과 명암이 크게 달라질 수 있음을 보여준다.



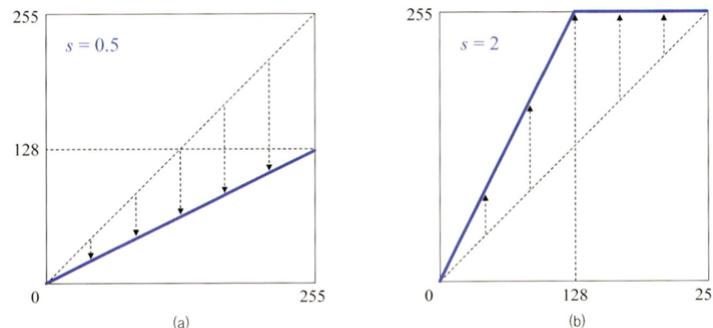


## 4. 딥러닝의 응용

### 명암비 조절

#### 개요

명암비는 영상에서 밝은 영역과 어두운 영역이 얼마나 차이가 나는지를 의미한다. 명암비가 높아지면 어두운 부분은 더 어둡게 표현되고 밝은 부분은 더 밝게 표현되어 전체적인 대비가 강해진다. 반대로 명암비가 낮으면 전체 영상이 평탄하고 흐릿하게 보이면서 디테일이 약해진다.



**그림** 대비 조절 계수인  $s$  값에 따라 영상의 픽셀 분포가 어떻게 변하는지를 보여준다. 왼쪽 그래프는  $s = 0.5$ 인 경우로 입력 픽셀값을 절반으로 축소해 출력 픽셀 값을 생성한다. 이때 출력 픽셀의 가능한 값이 0부터 128 사이에 머물게 되므로 전체적으로 영상이 더 어둡고 평탄하게 표현되며 명암비가 감소한다. 즉, 어두운 영역과 밝은 영역의 차이가 줄어들기 때문에 시각적으로 흐릿하고 대비가 약한 영상이 된다.

반면 오른쪽 그래프는  $s = 2$ 인 경우를 나타낸다. 이때 입력 영상에서 0~128 범위에 속하는 픽셀 값은 곱셈 계수에 의해 0~255 범위로 확대되어 명암비가 크게 증가한다. 즉, 픽셀 간 밝기 차이가 뚜렷해지면서 대비가 강한 영상이 된다. 그러나 입력 픽셀 값이 128을 초과하는 영역에서는 곱셈 연산 결과가 255를 넘어가므로 모든 값이 255로 포화되어 버린다. 이로 인해 밝은 영역의 세부 정보는 손실되며 과한 대비 조절이 가져올 수 있는 한계를 시각적으로 나타내고 있다.

명암비 조절의 핵심은 각 픽셀값에 일정한 곱셈 계수를 적용해 밝고 어두운 영역의 차이를 키우거나 줄이는 데 있다. 예를 들어 모든 픽셀 값에 1.5를 곱하면 밝은 쪽은 더 밝아지고 어두운 쪽은 더 어두워져 전체 대비가 강해진다. 반대로 0.7을 곱하면 밝은 값과 어두운 값이 서로 가까워져 화면이 부드럽고 흐릿해진다. 이런 방식은 식이 단순하고 구현도 쉬워서 명암비 조절의 가장 기본적인 형태로 많이 사용된다. 그러나 이 곱셈 방식에는 중요한 한계가 있다. 픽셀 값은 0~255 범위를 벗어나면 안 되는데 계수를 너무 크게 잡으면 곱셈 결과가 255를 넘어가 버린다. 이때 초과된 값은 모두 255로 잘려서 서로 다른 밝기였던 픽셀들이 한꺼번에 같은 값인 255로 몰리는 현상이 생긴다. 반대로 아주 작은 값을 곱하면 많은 픽셀이 0 근처로 떨어져 모두 검게 붙어버린다. 이렇게 상한 및 하한에 값이 몰리면 밝은 영역이나 어두운 영역의 미세한 차이가 사라져 세부 정보 손실이 발생한다. 눈으로 볼 때는 대비가 세다라고 느낄 수 있지만, 실제로는 중요한 디테일을 잃어버린 상태가 되는 셈이다. 따라서 실무에서는 단순 곱셈보다 더 정교한 방법을 사용하며 명암비를 조절할 때는 다음과 같은 요소들을 함께 고려하는 것이 좋다.

#### ● 감마 보정

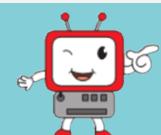
사람의 시각 인지 특성에 맞춰 명암을 조절하는 방식이다. 단순 비례 연산보다 자연스러운 대비 향상이 가능하며 특히 과도한 명암 손실을 방지하는 데 효과적이다.

#### ● 비선형 대비 조절

특정 범위의 픽셀값만 집중적으로 조정하거나 히스토그램 기반 조정 기법을 적용해 대비를 변화시키는 방식이다. 어두운 영역 또는 밝은 영역 등 특정 구간의 디테일을 강화하는 데 유용하다.

#### ● 컬러 영상 대비 조절

컬러 영상의 경우 채널 간 균형이 깨지면 색 왜곡이 발생할 수 있다. 채널 간 균형은 RGB 각각의 색상 채널이 서로 비슷한 비중과 상대적 관계를 유지해야 자연스러운 색감이 형성된다는 의미다. 세 채널 중 하나만 크게 증가하거나 감소하면 특정 색이 과도하게 강조되거나 반대로 약해져 원본과 다른 색조로 보이게 된다. 따라서 전체 RGB 채널에 동일한 계수를 적용하거나 Lab<sup>랩</sup> 색 공간의 밝기 채널을 이용해 밝기 정보만 분리 조정하면 원본 색감을 유지한 채 안정적인 대비 향상이 가능하다. Lab 색 공간은 인간의 시각 인지 특성을 반영해 밝기(L) 정보와 색상(a, b) 정보를 분리하여 표현하는 색 공간이다.





## 4. 딥러닝의 응용

### ◀ 히스토그램 분석

#### ◆ 개요

히스토그램은 영상의 픽셀값 분포를 막대 그래프 형태로 시각화한 것이다. 히스토그램을 분석하면 영상의 밝기 분포, 명암 대비 상태, 노출 정도 등을 객관적으로 이해할 수 있다. 그레이스케일 또는 컬러 영상의 각 픽셀 값을 구간별로 집계해 그래프 형태로 표현하는 방식이며 막대가 한쪽에 치우친 경우에는 영상 전체가 지나치게 어둡거나 밝은 상태임을 의미한다. 또한 특정 영역에 픽셀이 몰려 있다면 대비가 낮고 화면이 평평하게 보이는 영상일 가능성이 크다. 히스토그램은 이러한 정보를 기반으로 영상 품질을 평가하고 어떤 향상 기법을 적용하는 것이 적절한지 판단하는 기준을 제공한다.

#### ◆ 스트레칭

히스토그램 스트레칭은 픽셀값의 범위를 가능한 넓게 확장해 전체적인 대비를 높이는 기법이다. 영상 내 최소 픽셀값과 최대 픽셀값을 기준으로 선형 변환을 적용해 0~255 범위 전체를 활용하도록 재분배함으로써 밝고 어두운 영역의 차이를 자연스럽게 키운다. 과도한 대비 변화 없이 선명도를 향상시키는 특성이 있어 조명이 부족한 영상이나 흐릿한 이미지 보정에 효과적이다.

딥러닝 전처리에서는 입력 영상의 다이내믹 레인지를 확장해 엣지<sup>edge</sup>와 패턴을 분명하게 만들어 특징 학습을 강화하는 데 사용된다. 엣지는 영상에서 밝기 값이 급격하게 변하는 지점인 두 영역의 경계가 뚜렷하게 나타나는 부분을 의미한다. 대부분 물체의 윤곽, 경계선, 모서리, 형태 변화가 발생하는 위치가 엣지에 해당한다. 다이내믹 레인지를 확장하는 것은 매우 중요한 역할을 한다. 다이내믹 레인지는 영상이 표현할 수 있는 가장 어두운 부분과 가장 밝은 부분의 폭, 즉 명암 표현 범위를 의미한다. 이 범위가 좁으면 밝기 차이가 거의 느껴지지 않아 화면 전체가 흐릿하고 평평해 보이지만, 범위가 넓어지면 어두운 영역과 밝은 영역이 뚜렷하게 구분되어 영상이 더 선명하게 표현된다. 이러한 특성은 CNN이 학습하는 방식과 직접적으로 연결된다. CNN은 영상 속에서 선, 모서리, 윤곽선과 같은 엣지, 질감, 무늬, 반복 구조와 같은 패턴을 기반으로 특징을 추출해 피쳐 맵을 형성한다. 그런데 대비가 낮거나 영상이 평평하면 엣지와 패턴이 흐릿하게 묻혀 버려 신경망이 구조적 특징을 제대로 감지하지 못한다. 반대로 다이내믹 레인지를 적절히 확장하면 엣지의 경계가 뚜렷해지고 패턴의 반복 구조가 선명해져 CNN이 인식해야 할 시각적 단서가 더 강하게 드러난다. 결국 이는 학습 과정에서 모델이 더 풍부한 특징 정보를 파악하고 구별할 수 있도록 도와 분류, 검출, 인식 성능을 향상시키는 결과로 이어진다. 따라서 딥러닝 전처리에서 대비 조절이나 히스토그램 기반 변환을 적용하는 목적은 단순히 이미지를 보기 좋게 만드는 것이 아니라 엣지와 패턴을 선명하게 만들어 모델이 학습해야 할 정보의 밀도를 높이는 것이다.

#### ◆ 평활화

히스토그램 평활화는 픽셀값의 분포를 넓게 퍼뜨려 전체적으로 균일한 밝기 분포를 갖도록 만드는 기법이다. 이 과정을 통해 명암 차이가 작은 영상에서도 구조적 디테일이 강조되며 흐릿하게 보이던 경계나 형태가 한층 더 선명하게 드러난다. 이러한 특성 덕분에 흐릿하고 대비가 약한 영상 품질을 자연스럽게 개선하는 데 매우 효과적이다. 다만 히스토그램 평활화를 과도하게 적용하면 미세한 노이즈까지 지나치게 강조되거나 대비가 과하게 증폭되어 부자연스러운 결과가 나타날 수 있으므로 영상의 특성에 맞춰 적절한 강도로 조정하는 것이 중요하다.

컬러 영상의 경우에는 각 채널에 동일하게 평활화를 적용하면 색 균형이 무너져 색 왜곡이 발생할 수 있다. 이를 피하기 위해 보통 YCrCb<sup>와이드알씨비</sup> 또는 Lab<sup>랩</sup> 색 공간으로 변환한 뒤에 밝기 정보를 담당하는 채널에만 평활화를 적용하는 방식이 널리 사용된다. YCrCb 색 공간은 밝기 정보(Y)와 색차 정보(Cr, Cb)를 분리해 표현하기 때문에 밝기 조절 과정에서 색감이 변하는 문제를 방지할 수 있으며 Lab 색 공간 또한 밝기 정보와 색상 정보가 분리된 형태로 구성되어 있어 색 왜곡 없이 대비 향상이 가능하다. 딥러닝 전처리 측면에서도 히스토그램 평활화는 매우 유용하다. 객체와 배경의 경계가 흐릿하거나 조도 차이가 작은 영상에서 평활화를 적용하면 엣지, 윤곽, 패턴이 선명해져 CNN이 특징을 더 확실하게 감지할 수 있다. 결국 이는 피쳐 맵의 품질 향상 → 특징 학습 강화 → 분류 및 검출 성능 향상으로 이어지기 때문에 데이터가 제한적이거나 촬영 환경이 일정하지 않은 학습 조건에서 특히 도움을 준다.

